CUDA

CPU + GPU

CUDA

- Compute Unified Device Architecture
- NVIDIA

- C/C++
- Python
- Matlab

Установка CUDA

- GPU с поддержкой CUDA
- Драйвер GPU
- Пакет CUDA SDK
- Path путь к компилятору cl.exe


Основные понятия

- Host
 - Центральный процессор CPU
- Host memory
 - Оперативная память центрального процессора
- Device
 - Графический процессор GPU
 - Нумерация GPU: 0, 1, 2, ...
- Device memory
 - Оперативная память графического процессора
- Компилятор NVCC

Host

- Хозяин
- Принимающий (гостей), принимающая сторона
- Организовать, проводить
- ИТ
- Хостинг сайта
- Hosts IP / host name
- Host OS / Guest OS
- Host CPU

Программа CUDA



nvcc

- Device code
- Nvidia CUDA Compiler

- Host code
- Standard C++ host compiler
 - gcc and g++ (Linux)
 - cl.exe (Windows)

hello.c

```
#include <stdio.h>
int main()
{
    printf("Hello, World!\n");
}
```

hello.c – gcc – a.out

```
.. sample_data
a.out
hello.c
```

```
[18] !cat hello.c
    #include <stdio.h>
    int main()
      printf("Hello, World!\n");
[20] !gcc hello.c
     !./a.out
    Hello, World!
```

Colab

- colab.research.google.com
- Google account

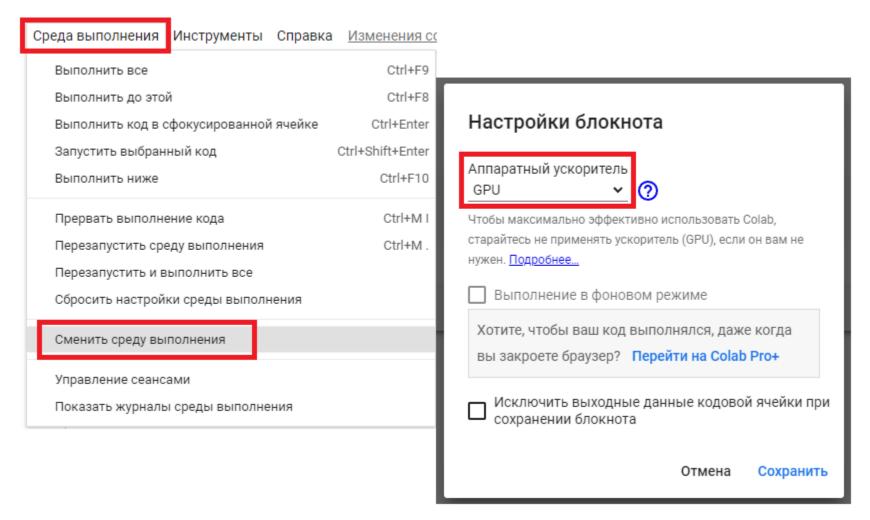
hello.cu (no device code)

```
#include <stdio.h>
int main(void)
{
    printf("Hello, World!\n");
}
```

hello.cu -> nvcc -> a.exe

```
hello.cu - Notepad
                                ×
File Edit Format View Help
#include <stdio.h>
int main()
{
    printf("Hello World!\n");
}
   F:\cuda>nvcc hello.cu
   hello.cu
       Creating library a.lib and object a.exp
   F:\cuda>a
   Hello World!
```

Google Colab – Runtime – GPU



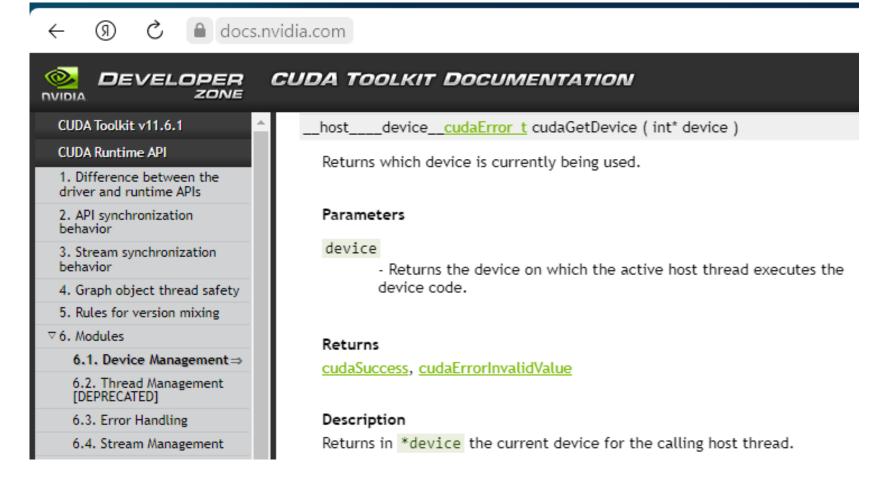
hello.cu - nvcc - a.out



dev.cu

```
#include <stdio.h>
int main()
    int dev;
    cudaGetDevice ( &dev );
    printf( "Current Device: %d\n", dev );
```

cudaGetDevice



NVCC

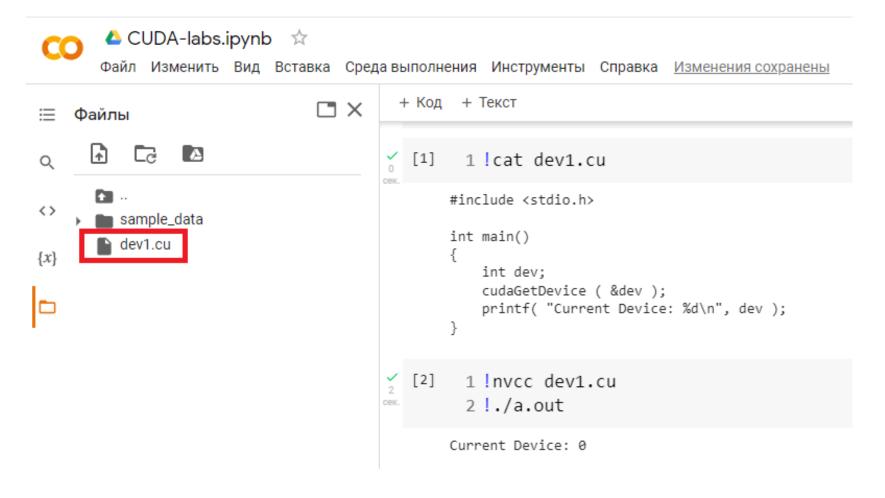
Nvidia CUDA Compiler

```
F:\cuda>nvcc dev1.cu
dev1.cu
Creating library a.lib and object a.exp
F:\cuda>a
Current Device: 0
```

Output file name

```
F:\cuda>nvcc dev1.cu -o dev1.exe
ldev1.cu
   Creating library dev1.lib and object dev1.exp
F:\cuda>dir dev1.* /b
dev1.cu
dev1.exe
dev1.exp
dev1.lib
F:\cuda>dev1
Current Device: 0
```

dev1.cu -> nvcc -> a.out



Виды функций

Функция	Вызов	Выполнение
host	CPU	CPU
global	CPU	GPU
device	GPU	GPU

device code + host code

```
#include <stdio.h>
 global void mykernel() {
int main() {
                               kernel launch
  mykernel<<<1,1>>>();
  printf("Hello World!\n");
```

```
hello2.cu - Notepad
                                 ×
File Edit Format View Help
#include <stdio.h>
  global void mykernel() {
int main() {
  mykernel<<<1,1>>>();
  printf("Hello World!\n");
Ln 9, Col 2
                  Windows (CRLF)
              100%
                              UTF-8
```

```
1 !nvcc hello2.cu
2 !./a.out
```

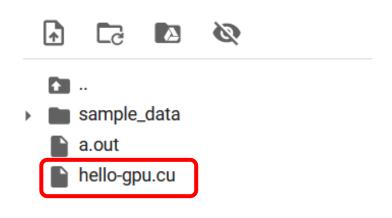
Hello World!

```
F:\cuda>nvcc hello2.cu
hello2.cu
Creating library a.lib and object a.exp
F:\cuda>a
Hello World!
```

CPU + GPU

```
#include <stdio.h>
global void mykernel() {
 printf("Hello, GPU!\n");
int main() {
 mykernel<<<1,1>>>();
 printf("Hello, CPU!\n");
```

CPU + GPU: Результаты

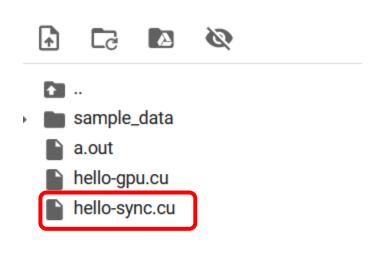


```
!cat hello-gpu.cu
       #include <stdio.h>
         global void mykernel() {
          printf("Hello, GPU!\n");
        int main() {
          mykernel<<<1,1>>>();
          printf("Hello, CPU!\n");
/<sub>ls</sub> [13] !nvcc hello-gpu.cu
        !./a.out
       Hello, CPU!
```

Синхронизация

```
#include <stdio.h>
 global void mykernel() {
 printf("Hello, GPU!\n");
int main() {
 mykernel<<<1,1>>>();
 printf("Hello, CPU!\n");
  cudaDeviceSynchronize();
```

Синхронизация: Результаты



```
[14] !cat hello-sync.cu
    #include <stdio.h>
      global void mykernel() {
      printf("Hello, GPU!\n");
     int main() {
      mykernel<<<1,1>>>();
      printf("Hello, CPU!\n");
      cudaDeviceSynchronize();
[15] !nvcc hello-sync.cu
     !./a.out
     Hello, CPU!
     Hello, GPU!
```

GPU: 5 потоков

```
#include <stdio.h>
 global void mykernel() {
 printf("Hello, GPU!\n");
int main() {
 mykernel<<<1,5>>>();
 printf("Hello, CPU!\n");
  cudaDeviceSynchronize();
```

Блоки и потоки

- (x,y,z)
- (x,y,z)



- ..
- sample_data
 - a.out
 - hello-gpu.cu
 - hello-sync-5.cu
 - hello-sync.cu

```
[16] !cat hello-sync-5.cu
       #include <stdio.h>
         global void mykernel() {
         printf("Hello, GPU!\n");
       int main() {
         mykernel<<<1,5>>>();
         printf("Hello, CPU!\n");
         cudaDeviceSynchronize();
[17] !nvcc hello-sync-5.cu
       !./a.out
       Hello, CPU!
       Hello, GPU!
       Hello, GPU!
       Hello, GPU!
       Hello, GPU!
       Hello, GPU!
```

Задание

- Википедия
 - CUDA (RU/EN)
- Версия / Архитектура / Видеокарты
 - 1.0 / Tesla / 8800, 870
 - 5.0 / Maxwell / 750 Ti / M10
 - 8.0 / Ampere / 3060, A100
- Version features and specifications
 - Compute capability (version)
 - Data Types
 - Tensor Core

Модель видеокарты

- Диспетчер устройств / Device Manager
 - [Win + X] Device Manager
 - Start Settings Devices Printers Device manager
 - [Win + R] devmgmt.msc
 - Search Device Manager





Параметры видеокарты

• nvidia.com – Поиск – Спецификации

Wiki – CUDA – GPUs – compute capability –
 5.x (Maxwell) –
 CUDA SDK 6.5 ... 11.8

Спецификации GPU			
Ядер CUDA	640		
Базовая тактовая частота	1020 MHz		
Тактовая частота с ускорением	1085 MHz		
Спецификации памяти			
Быстродействие памяти (<u>Gbps</u>)	5,4		
Объем памяти	2048 MB		
Интерфейс памяти	128-bit GDDR5		
Максимальная полоса пропускания памяти	86,4 GB/sec		
Возможности			
Программное окружение	CUDA		

GeForce GTX 750 Ti

Версия компилятора

!nvcc --version

```
nvcc: NVIDIA (R) Cuda compiler driver
Copyright (c) 2005-2021 NVIDIA Corporation
Built on Sun_Feb_14_21:12:58_PST_2021
Cuda compilation tools, release 11.2, V11.2.152
Build cuda 11.2.r11.2/compiler.29618528 0
```

Параметры, ключи, опции...

- Is -a
- Is -la

•

- nvcc --version
- nvcc --help

System Management Interface

```
!nvidia-smi
Sun Nov 6 09:10:58 2022
                                               CUDA Version: 11.2
 NVIDIA-SMI 460.32.03 Driver Version: 460.32.03
 GPU Name Persistence-M Bus-Id Disp.A | Volatile Uncorr. ECC
 Fan Temp Perf Pwr:Usage/Cap | Memory-Usage | GPU-Util Compute M.
                                                             MTG M.
     Tesla T4
                  off | 00000000:00:04.0 off |
                   9W / 70W | 0MiB / 15109MiB | 0% Default
!nvidia-smi --list-gpus
GPU 0: Tesla T4 (UUID: GPU-53534127-5127-60bb-6b1f-a6af33046c2d)
```

Спецификации видеокарты

- NVIDIA Tesla T4
 - Версия 7.5 / Архитектура Turing
 - Ядра NVIDIA CUDA 2560
 - Производительность операций с одинарной точностью (FP32) 8,1 Терафлопс
 - Операции INT8 130 тера-операций в секунду (TOPS)
 - Объем видеопамяти 16 ГБ GDDR6
 - Пропускная способность памяти 320+ Гбит/с
 - Энергопотребление 70 Вт
- Цена?

cudaGetDeviceProperties



Returns information about the compute-device.

Parameters

prop

Properties for the specified device

device

- Device number to get properties for

Объявляем тип переменной

int* x

int x

Параметры видеокарты

#include <stdio.h>

```
int main(int argc, char **argv) {
  cudaDeviceProp props;
  cudaGetDeviceProperties(&props, 0);
  printf("GPU %d: %s\n", 0, props.name);
  printf("Compute capability: %d.%d\n",
  props.major, props.minor);
}
```

Формат вывода

- %d
- %x %h
- %0
- •
- Decimal
- Hexadecimal
- Octal
- Binary

Результаты

```
!cat comp_cap.cu
#include <stdio.h>
int main(int argc, char **argv) {
 cudaDeviceProp props;
 cudaGetDeviceProperties(&props, 0);
 printf("GPU %d: %s\n", 0, props.name);
 printf("Compute capability: %d.%d\n", props.major, props.minor);
!nvcc comp_cap.cu
./a.out
GPU 0: Tesla T4
Compute capability: 7.5
```

Динамические переменные

Calls	C function	CUDA API
Memory	Host	Device
Выделение	malloc()	cudaMalloc()
памяти		
Копирование	memcpy()	cudaMemcpy()
данных		
Освобождение	free()	cudaFree()
памяти		

cudaMemcpy



Copies data between host and device.

Parameters

dst

- Destination memory address

src

- Source memory address

count

- Size in bytes to copy

kind

- Type of transfer

```
#include <stdio.h>
 global void add(int *x) {
 *x += 10; }
int main(void) {
 int cpu_a, *gpu_a, size = sizeof(int);
 cpu_a = 2;
 cudaMalloc((void **)&gpu_a, size);
 cudaMemcpy(gpu_a, &cpu_a, size, cudaMemcpyHostToDevice);
 add<<<1,1>>>(gpu_a);
 cudaMemcpy(&cpu_a, gpu_a, size, cudaMemcpyDeviceToHost);
 cudaFree(gpu_a);
 printf("a = %d\n", cpu_a); }
```

Разыменование

*X

!cat add.cu

```
#include <stdio.h>
global void add(int *x) {
 *x += 10;
int main(void) {
  int cpu a, *gpu a, size = sizeof(int);
  cpu a = 2;
  cudaMalloc((void **)&gpu a, size);
  cudaMemcpy(gpu_a, &cpu_a, size, cudaMemcpyHostToDevice);
  add<<<1,1>>>(gpu a);
  cudaMemcpy(&cpu a, gpu a, size, cudaMemcpyDeviceToHost);
  cudaFree(gpu a);
  printf("a = %d\n", cpu_a);
```

!nvcc add.cu !./a.out

a = 12

Материалы

CUDA Tutorial

https://cuda-tutorial.readthedocs.io/en/latest/tutorials/tutorial01/

Тумаков 2017 Технология программирования CUDA

https://e.lanbook.com/book/130543

Минязев 2021 Параллельное программирование (MPI, OpenMP, CUDA)

https://e.lanbook.com/book/264890

Тоуманнен 2020 Программирование GPU при помощи Python и CUDA

https://e.lanbook.com/book/179469

Елесина 2020 Основы работы с технологией параллельных вычислений CUDA

https://e.lanbook.com/book/220436

Паттерсон 2018 Глубокое обучение с точки зрения практика

https://e.lanbook.com/book/116122

Боресков 2010 Основы работы с технологией CUDA

https://e.lanbook.com/book/1260

Малявко 2015 Параллельное программирование на основе технологий OpenMP, MPI, CUDA https://e.lanbook.com/book/118245